


PROYECTO MODELOS LINEALES 2026

# ANÁLISIS PREDICTIVO de edad de cangrejos



Autores

**Manuel Recayte y Asier Letona**


# Objetivo y Motivación

## Motivación

La edad de los cangrejos es un dato clave en la industria pesquera: determina el precio de venta según la calidad de la carne, evita la captura prematura que afecta la población, y permite a los criaderos optimizar el momento de cosecha de forma sostenible.

## Objetivo

Se busca realizar un análisis exploratorio que permita explicar/predecir la edad de los cangrejos a partir de las demás variables mediante un modelo de regresión lineal.



# Variables del Estudio

## Variable Cualitativa y Cuantitativas

Sex: sexo biológico (M, F, I)

Length: longitud máxima

Diameter: diámetro transversal

Height: altura vertical

Weight: peso total



Shucked Weight: peso sin caparazón

Viscera Weight: peso de las vísceras

Shell Weight: peso de caparazón

## Variable Objetivo





Age: edad del cangrejo



# Descripción de las Variables





| Variable       | Min.    | 1st Qu.  | Median   | Mean     | 3rd Qu.  | Max.     |
|----------------|---------|----------|----------|----------|----------|----------|
| Length         | 0.18750 | 1.12500  | 1.36250  | 1.31130  | 1.53750  | 2.03750  |
| Diameter       | 0.13750 | 0.87500  | 1.06250  | 1.02090  | 1.20000  | 1.62500  |
| Height         | 0.00000 | 0.28750  | 0.36250  | 0.34940  | 0.41250  | 2.82500  |
| Weight         | 0.05670 | 12.67220 | 22.79300 | 23.56730 | 32.78620 | 80.10150 |
| Shucked.Weight | 0.02835 | 5.34388  | 9.53961  | 10.20734 | 14.27397 | 42.18406 |
| Viscera.Weight | 0.01418 | 2.66485  | 4.86194  | 5.13655  | 7.20077  | 21.54562 |
| Shell.Weight   | 0.04252 | 3.71378  | 6.66213  | 6.79584  | 9.35534  | 28.49125 |
| Age            | 1.00000 | 8.00000  | 10.00000 | 9.95500  | 11.00000 | 29.00000 |

# Variables contra Edad






# Variables contra Edad





# Para terminar de concluir multicolinealidad...



## Conclusiones de la matriz de correlación

- Las variables de dimensión (Length, Diameter, Height) y las de peso (Weight, Shucked Weight, Viscera Weight, Shell Weight) presentan correlaciones muy altas entre sí (círculos azul oscuro), lo que indica fuerte multicolinealidad entre los predictores.
- La variable objetivo Age muestra correlaciones moderadas-bajas con todas las demás variables (círculos azul claro), siendo Shell Weight la que presenta la correlación más alta con la edad.

# Diagnosticos de Multicolinealidad

Como instancia formal de la evaluacion, ajustando modelo con todas las variables, se realizo el VIF  
(VIF > 10, colinealidad severa)

$$VIF_{\text{Weight}} = 106,80$$

$$VIF_{\text{Length}} = 40,48$$


$$VIF_{\text{Viscera.Weight}} = 17,07$$

$$VIF_{\text{Diameter}} = 41,99$$

$$VIF_{\text{Shucked.Weight}} = 27,77$$

$$VIF_{\text{Shell.Weight}} = 21,03$$

*Que camino tomamos para combatir este problema?*





# Selección de Variables

**Decidimos usar LASSO**

**Metodo que reduce a 0  
coeficientes de variables  
redundantes**

**Variables seleccionadas:**

- Diameter
- Sex.Det
- Height
- Shucked.Weight
- Shell.Weight

**Obtuvimos:**

VIFDiameter = 8,21  
VIFShell.Weight = 6,93  
VIFShucked.Weight = 5,83  
VIFHeight = 3,46  
VIFSex.Det = 1,49

# Análisis sobre la Heterocedasticidad

El ajuste por MCO de este modelo arrojó estimaciones puntuales altamente significativas bajo los supuestos tradicionales

Sin embargo, con Breusch-Pagan se obtuvo un estadístico de 376,5 con un p-valor prácticamente nulo rechazando tajantemente la hipótesis de varianza constante (homocedasticidad).

***Mas problemas... Solucionables***



Utilizando el estimador HC4 podemos generar errores estandar mas robustos, y poder ignorar el supuesto de la homoscedasticidad

# Supuesto de Normalidad

Se realizó un análisis tanto visual como matematico de la normalidad ambos con resultados feos

El Test de Shapiro-Wilk de normalidad dio un p-valor estadísticamente igual a 0, y el grafico no hizo mas que confirmar este resultado

Al tener casi 4000 observaciones, aplicamos consistencia asintótica gracias al TLC.



Los resultados mantienen su validez

¿¿¿Solución???



# Datos Atípicos

La eliminación de datos atípicos se realizó de manera visual, utilizando la distancia de Cook y eliminando los datos que se desmarcaban más del resto



A pesar de haber quitado datos atípicos, no se vió una gran mejora, probablemente debido a la inmensa cantidad de observaciones presentes en el dataset.





# Análisis de Linealidad

¡Buenas noticias!

Al realizar los graficos correspondientes para analizar linealidad, es apreciable que este supuesto SI SE CUMPLE!!!

Por ese motivo no hubo que realizar ningún tipo de ajuste extra.

Component + Residual Plots





# Desempeño Predictivo


Bueno... se intentó



Perdimos contra la biología. El modelo predice “bien” hasta los 11 años, a partir de ahí se va al car...

Posiblemente causado por la detención en el crecimiento de los cangrejos

Evaluación del Desempeño Predictivo en Conjunto de Prueba  
La línea roja discontinua representa la predicción ideal ( $y = x$ )





# Conclusiones y Próximos Pasos

Logramos desarrollar un modelo simplificado que estima la edad del cangrejo utilizando únicamente 5 variables morfológicas fáciles de medir. El análisis demostró una precisión aceptable principalmente en el rango de ejemplares jóvenes y adultos de mediana edad, pero evidenció una clara limitación biológica en las etapas avanzadas: a partir de los 12 años, el estancamiento natural del crecimiento del crustáceo provoca una subestimación sistemática de la edad.

El estancamiento biológico del crecimiento limita la predicción en edades avanzadas con un modelo único. Para mitigar este techo, se propone como trabajo futuro implementar un enfoque por tramos. Bajo este esquema, un algoritmo clasificaría primero al ejemplar según una o varias de las variables y luego arrojaría un conjunto de estimadores  $\beta$  específicos para esa etapa.

**iii MUCHAS GRACIAS!!!**