

Proyecto Modelos Lineales — 2026

Manuel Recayte — 5.973.870-3

Asier Letona — 5.575.911-3

3 de septiembre de 2026

1. Obejetivo y Descripción de Variables

Se busca realizar un análisis exploratorio que permita explicar/predecir la edad de los cangrejos a partir de las demás variables mediante un modelo de regresión lineal.

Motivación

El mercado de los cangrejos es un sector grande e importante dentro de la industria pesquera, y por lo tanto conocer y poder estimar una característica tan importante de los mismos, como lo es su edad es considerado un pilar fundamental para garantizar una gestión sostenible del recurso.

Determinar la edad de los cangrejos es muy importante por dos motivos principales:

- **Pescadería:** Cuando se realiza la pesca de este animal, es de gran importancia saber la edad de los individuos pescados ya que su precio de venta puede variar según la edad de los cangrejos debido a la calidad de su carne. Asimismo, no interesa pescar cangrejos en etapas prematuras en demasía ya que eso puede resultar en una disminución en la población del animal. [8] [7]
- **Criaderos:** En la actualidad existen criaderos de cangrejos, a los cuales les interesa saber cuando realizar la cosecha para maximizar ganancias sin poner en riesgo la continuación del negocio.

Bajo este escenario, el propósito central de este trabajo consiste en desarrollar un modelo predictivo que, a partir de mediciones morfológicas externas y de fácil obtención, sea capaz de estimar con precisión la edad de los individuos.

1.1. Descripción de Variables

A continuación esta la descripción cada una de las variables en el conjunto de datos, especificando su tipo, unidad de medida y una descripción conceptual.

1.1.1. Variables Cualitativas

- **Sex (Sexo):** Variable categórica (cualitativa nominal) que indica el género biológico del cangrejo.
 - **Valores posibles:** M (Masculino), F (Femenino), e I (Indeterminado).

La posibilidad de que a un cangrejo se le adjudique sexo indeterminado recae en que a estos animales, como a muchos otros cetáceos las características sexuales no se le desarrollan hasta cierto punto de su madurez, donde se empiezan a diferenciar hembras de machos.

1.1.2. Variables Cuantitativas Continuas

- **Length (Longitud):** Variable cuantitativa continua que mide la longitud máxima del cangrejo. Rango observado en la muestra: [0,19, 2,04].
- **Diameter (Diámetro):** Variable cuantitativa continua que indica el diámetro transversal del cangrejo. Rango observado en la muestra: [0,14, 1,63].
- **Height (Altura):** Variable cuantitativa continua que representa la altura o grosor vertical del cangrejo. Rango observado en la muestra: [0,00, 2,82].
- **Weight (Peso Total):** Masa total del cangrejo vivo completo. Rango observado en la muestra: [0,07, 80,10].
- **Shucked Weight (Peso sin Caparazón):** Peso del cangrejo una vez extraído su caparazón. Rango observado en la muestra: [0,03, 42,18].
- **Viscera Weight (Peso de las Vísceras):** Peso de los órganos internos y fluidos del cangrejo inmediatamente después de la evisceración. Rango observado en la muestra: [0,01, 21,55].
- **Shell Weight (Peso del Caparazón):** Peso del caparazón que protege al cangrejo. Rango observado en la muestra: [0,04, 28,49].

Las variables de longitud están medidas en pies ($1ft = 30,48cm$), mientras que las de peso en libras ($1lb = 453,59gms$).

1.1.3. Variable Objetivo (Cuantitativa Discreta)

- **Age (Edad):** Variable cuantitativa discreta que representa la edad real del cangrejo. Rango observado en la muestra: [1, 29].

2. Análisis de las Variables

Se realizó una visualización y análisis de la distribución de las variables con respecto a la edad y sus correlaciones.

2.1. Descripción de datos

Descripción univariada: En primer lugar se obtuvo, usando la función `summary()`, métricas relevantes sobre cada variable.

La Tabla 1 contiene las métricas descriptivas obtenidas mediante la función `summary()` en R sobre la muestra total de 3,893 registros.

Cuadro 1: Métricas estadísticas descriptivas del conjunto de datos (Salida de R).

Variable	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Length	0.19	1.16	1.36	1.31	1.54	2.04
Diameter	0.14	0.88	1.06	1.02	1.20	1.63
Height	0.00	0.29	0.36	0.35	0.41	2.83
Weight	0.06	12.67	22.79	23.57	32.79	80.10
Shucked.Weight	0.03	5.34	9.54	10.21	14.27	42.18
Viscera.Weight	0.01	2.66	4.86	5.14	7.20	21.55
Shell.Weight	0.04	3.71	6.66	6.80	9.36	28.49
Age	1.00	8.00	10.00	9.96	11.00	29.00

2.2. Análisis Bivariado y Relación con la Variable Respuesta (Y)

Para comprender la estructura interna del conjunto de datos de manera previa a la modelación, es relevante analizar cómo se asocia cada variable predictora con la variable objetivo **Age**.

2.2.1. Variables Numéricas: Correlación Lineal

Se calculó el coeficiente de correlación de Pearson (r) entre cada característica física y la edad para cuantificar la fuerza y dirección de su asociación lineal (ver Tabla 2).

Cuadro 2: Coeficientes de correlación de Pearson con respecto a la variable **Age**.

Variable Predictora (X)	Correlación con Age (r)
Shell.Weight	0.63
Diameter	0.58
Length	0.56
Height	0.55
Weight	0.54
Viscera.Weight	0.50
Shucked.Weight	0.42

Como es apreciable, todas las dimensiones y pesos guardan una relación lineal positiva moderada-alta con la edad. El peso del caparazón (**Shell.Weight**) presenta la correlación más elevada ($r = 0,6276$), lo cual guarda estricta coherencia biológica.

2.2.2. Variable Categórica: Relación del Sexo con la Edad

La distribución de la edad varía notablemente según el estado madurativo del cangrejo: los individuos clasificados con sexo Indeterminado (I) concentran sus observaciones en edades tempranas de rápido crecimiento lineal (media $\approx 7,9$), mientras que los adultos Machos (M) y Hembras (F) presentan distribuciones similares desplazadas hacia la derecha (media de $\approx 10,9$), reflejando la estabilización del tamaño físico en la adultez.




Figura 1: Distribución de la edad de los cangrejos según su categoría de sexo.

3. Selección de Variables y Ajuste del Modelo

3.1. Selección de Variables y Diagnóstico de Multicolinealidad

El análisis preliminar de los datos evidenció una problemática metodológica común en estudios morfométricos: la alta colinealidad intrínseca entre los predictores. Debido a que las dimensiones del cangrejo (**Length**, **Diameter**, **Height**) y las distintas mediciones de su masa (**Weight**, **Shucked.Weight**, **Viscera.Weight**, **Shell.Weight**) crecen de manera simultánea a lo largo de la edad del animal, las variables explicativas contienen información fuertemente redundante.

Para evaluar formalmente la gravedad de esta condición, se procedió en primer lugar al ajuste por mínimos cuadrados ordinarios (MCO) de un modelo saturado que incluyera la totalidad de los predictores disponibles (**modelo_todas_las_variables**). Sobre este modelo global se computó el Factor de Inflación de la Varianza (VIF), el cual mide el grado en que la varianza de un coeficiente de regresión estimado se incrementa a causa de la multicolinealidad con las demás variables independientes. Los resultados numéricos revelaron una patología estadística crítica, registrando:

$$\begin{array}{ll} \text{VIF}_{\text{Weight}} = 106,80 & \text{VIF}_{\text{Diameter}} = 41,99 \\ \text{VIF}_{\text{Length}} = 40,48 & \text{VIF}_{\text{Shucked.Weight}} = 27,77 \\ \text{VIF}_{\text{Viscera.Weight}} = 17,07 & \text{VIF}_{\text{Shell.Weight}} = 21,03 \end{array}$$

Bajo los estándares estadísticos, un umbral de $\text{VIF} > 10$ denota una multicolinealidad severa. En términos prácticos, esta condición provoca una enorme inestabilidad en las estimaciones MCO: los errores estándares de los coeficientes se inflan artificialmente, lo cual reduce drásticamente los estadísticos t de significación individual y hace que los coeficientes sean extremadamente sensibles a pequeñas fluctuaciones o cambios en la muestra, llegando incluso a alterar el signo algebraico esperado biológicamente.

Para solucionar este inconveniente y transicionar hacia un modelo óptimo, parsimonioso y generalizable, se aplicó un método formal de selección de variables mediante regularización **Lasso** (Least Absolute Shrinkage and Selection Operator). El algoritmo de Lasso posee la propiedad geométrica de encoger los coeficientes de las variables redundantes o menos informativas hasta volverlos exactamente cero, operando de manera efectiva como un selector automático de variables.

A través de este proceso de optimización, el modelo Lasso descartó las variables con mayor redundancia de información estructural, específicamente **Length**, **Weight** y **Viscera.Weight**. Este algoritmo, usando como referencia **Sex.F** dio como significativo **Sex.I** pero insignificante a **Sex.M**, esto refleja que se puede explicar un cambio en la edad a partir de saber si el cangrejo es hembra o indeterminado, pero identificando si es hembra o macho no. Por esta razón y por su similitud en distribución se decidió utilizar únicamente la variable **Sex.Det** creada manualmente unificando cangrejos de sexo Determinado. [?] Teniendo eso en cuenta se seleccionó un subconjunto óptimo de 5 predictores esenciales:

1. **Diameter** (como indicador principal de la extensión transversal del caparazón).
2. **Sex.Det** (indicador de si se conoce el sexo del cangrejo o no).
3. **Height** (dimensión vertical del espécimen).
4. **Shucked.Weight** (indicador de la masa sin caparazón).
5. **Shell.Weight** (masa del caparazón).

Al reevaluar los factores de inflación de la varianza en este modelo refinado (**modelo_según_lasso**), se observó una reducción drástica y exitosa en los niveles de colinealidad: $\text{VIF}_{\text{Diameter}} = 8,21$, $\text{VIF}_{\text{Shell.Weight}} = 6,93$, $\text{VIF}_{\text{Shucked.Weight}} = 5,83$, $\text{VIF}_{\text{Height}} = 3,46$, y $\text{VIF}_{\text{Sex.Det}} = 1,49$. Al situar todos los indicadores por debajo del límite crítico, se estabilizó la estimación de los parámetros para el posterior análisis inferencial y predictivo.

3.2. Inferencia sobre los Parámetros y Corrección por Heterocedasticidad

El ajuste por MCO de este modelo arrojó estimaciones puntuales altamente significativas bajo los supuestos tradicionales. No obstante, al evaluar el comportamiento de los errores mediante el test formal de

heterocedasticidad de Breusch-Pagan, se obtuvo un estadístico de 376,5 con un p -valor prácticamente nulo ($< 0,001$), rechazando tajantemente la hipótesis de varianza constante (homocedasticidad).

Ante la presencia de heterocedasticidad, los coeficientes MCO siguen siendo insesgados, pero los errores estándares clásicos quedan severamente distorsionados, invalidando los intervalos de confianza tradicionales. Por consiguiente, se procedió a realizar inferencia robusta aplicando la matriz de covarianza consistente con heterocedasticidad de tipo **HC4**. La Tabla 3 expone la comparación de las pruebas de hipótesis y los respectivos intervalos de confianza al 95 %.

Cuadro 3: Comparación de inferencia clásica y robusta (HC4) para el modelo seleccionado.

Variable	Inferencia Clásica (MCO)			Inferencia Robusta (HC4)		
	Est.	Err. Est.	Int. Confianza 95 %	Est.	Err. Est.	Int. Confianza 95 %
(Intercept)	3.80	0.28	[3.25, 4.35]	3.80	0.67	[2.48, 5.12]
Diameter	4.44	0.41	[3.63, 5.25]	4.44	1.92	[0.68, 8.19]
Sex.DetI	-0.92	0.09	[-1.10, -0.73]	-0.92	0.11	[-1.13, -0.70]
Height	4.15	0.63	[2.91, 5.40]	4.15	8.85	[-13.19, 21.50]
Shucked.Weight	-0.41	0.01	[-0.44, -0.38]	-0.41	0.02	[-0.45, -0.38]
Shell.Weight	0.69	0.02	[0.64, 0.73]	0.69	0.09	[0.51, 0.86]

El análisis de los resultados bajo la corrección robusta HC4 denota cambios metodológicos profundos: la variable de altura (**Height**), que bajo MCO clásico ostentaba un error estándar pequeño y un p -valor ínfimo ($6,74 \times 10^{-11}$), al corregirse por heterocedasticidad expande dramáticamente su error estándar a 8,8490, volviéndose estadísticamente no significativa (p -valor = 0,6388) y conteniendo al cero en su intervalo robusto, reflejando que la precisión percibida originalmente era un espejismo derivado de la estructura heterocedástica de las varianzas en los residuos. Algo similar ocurre con el **Diameter** aunque no de manera tan drástica, manteniendo significancia con si se toma como vara un p -valor $< 0,05$, cuyo intervalo se ensancha sustancialmente.

3.3. Diagnóstico y Validación de Supuestos Críticos

3.3.1. El Supuesto de Normalidad y Teorema del Límite Central

La evaluación formal del supuesto de normalidad sobre los residuos studentizados mediante la prueba de Shapiro-Wilk arrojó un estadístico $W = 0,9182$ con un p -valor significativamente inferior a las cotas estándar ($< 0,001$), lo cual dictamina un alejamiento matemático de la distribución gaussiana teórica (patología visualizada también en las colas del QQ-Plot).

No obstante, desde la perspectiva de la teoría asintótica, **la no normalidad de los residuos no invalida la validez de las pruebas de hipótesis (t y F) ni la consistencia de los estimadores cuando se trabaja con muestras grandes**. De acuerdo al **Teorema del Límite Central (TLC)**, la distribución muestral de los estimadores MCO converge asintóticamente a una distribución normal, sin importar cuál sea la verdadera distribución de los errores en la población.

Esta flexibilización está ampliamente validada por la comunidad estadística, de referencia. Lumley et al. (2002) demuestran formalmente que en muestras que superan unos pocos cientos de observaciones, la violación del supuesto de normalidad carece de consecuencias prácticas medibles sobre el control de la tasa de error. En idéntica sintonía, Wooldridge (2015) establece que para propósitos de inferencia y aproximación de intervalos de confianza, el supuesto de normalidad en poblaciones grandes deja de ser un requerimiento estricto, dado que las distribuciones de los estadísticos de prueba se estabilizan asintóticamente bajo el TLC. Contando este estudio con $N = 3,893$ observaciones, la desviación detectada por el test de Shapiro-Wilk es metodológicamente irrelevante para la consistencia del análisis inferencial ejecutado.

3.3.2. Identificación y Eliminación de Datos Atípicos (Distancia de Cook)

Con la intención de estabilizar el comportamiento del modelo frente a desviaciones severas y reducir la varianza residual, se inspeccionó la presencia de observaciones atípicas mediante el cómputo de la distancia de Cook (D_i). Se ejecutó una estrategia iterativa de depuración secuencial que detectó y removió las observaciones




Figura 2: Gráfico que indica por cuantiles, la diferencia entre la distribución obtenida y la distribución normal usual.

con un impacto desproporcionado en el vector de parámetros ajustados. Se utilizó un baremo elegido de manera arbitraria, ya que el usual arrojaba un número muy bajo, superado por muchos datos.

Este filtrado iterativo provocó la eliminación de 5 observaciones y derivó en un modelo final relativamente estabilizado (`modelo_sin_outliers`). La exclusión de estas observaciones periféricas mejoró sensiblemente la eficiencia del estimador: el error estándar de los residuos (RSE) decreció de un valor inicial de 2,2357 a un valor limpio de 2,2179, reduciendo a la vez los errores estándar de los coeficientes individuales y dotando al modelo de una mayor robustez estructural para fines predictivos.




Figura 3: Gráfico de distancia de Cook, luego de la eliminación de los datos superiores a 0.022

3.4. El supuesto de Linealidad

Este supuesto fue el último analizado y se partió del modelo ya editado a partir de los restos de supuestos. Para este análisis se utilizó únicamente la visualización de las 4 variables numéricas seleccionadas mediante la

función `crPlots`, la cual arrojó la siguiente imagen.




Figura 4: Gráficos de visualización de linealidad.

Se puede apreciar que este supuesto si se cumple, por lo que no fue necesario realizar cambios para solucionarlo.

4. Evaluación del Desempeño Predictivo

De acuerdo con las directrices metodológicas rigurosas, evaluar la capacidad predictiva de un modelo sobre los mismos datos utilizados para su entrenamiento genera un diagnóstico sesgado y excesivamente optimista. Asimismo, coeficientes globales como el R^2 miden bondad de ajuste muestral mas no capacidad de generalización ante datos nuevos no observados.

Por ende, se dividió el dataset original en un conjunto de entrenamiento (*Train Set*) y un conjunto de validación independiente (*Test Set*). El modelo lineal se entrenó exclusivamente en el primero y se evaluó calculando el **Error Cuadrático Medio** (MSE) sobre el conjunto de prueba para medir el desempeño predictivo real. Los resultados comparativos de las dos estrategias de modelación lineal planteadas se resumen en la Tabla 4. En la cual aparecen los MSE obtenidos a partir de 3 modelos distintos, uno con todas las variables originales, otra con las variables obtenidas en el apartado de Seleccíon de Variables, y la última implementando el logaritmo en la variable objetivo con intención de encontrar una posible mejoría.

Los resultados presentados en la Tabla 4 exponen un comportamiento de alto valor analítico respecto al compromiso entre la complejidad del modelo y su capacidad de generalización. Sorprendentemente, el **Modelo Saturado** registra el menor error en el conjunto de prueba ($MSE = 3,9860$). Este fenómeno evidencia que, con fines estrictamente predictivos, la combinación de múltiples mediciones altamente correlacionadas aporta información geométrica y ponderada marginal que estabiliza las estimaciones ante datos nuevos, aun a costa de introducir severos problemas de multicolinealidad que invalidarían la inferencia individual de sus parámetros.

Cuadro 4: Evaluación del rendimiento predictivo basado en el Error Cuadrático Medio (MSE).

Configuración del Modelo	MSE en Datos Nuevos (Test Set)
Modelo Saturado (Variables Originales)	3.9860
Modelo Lineal en Escala Original (Variables Lasso)	4.7732
Modelo Lineal con Transformación Logarítmica $\log(Y)$	5.0359

Por otro lado, el **Modelo Lineal bajo la selección de Lasso** exhibe un incremento en el error (MSE = 4,7732). Este incremento representa el costo en sesgo que introduce la penalización matemática al forzar la parsimonia; si bien se resigna cierto margen de precisión pura en el *Test Set*, se obtiene un modelo sustancialmente más simple, interpretable y metodológicamente robusto para la explicación del fenómeno biológico.

Finalmente, la **Transformación Logarítmica** ($\log(Y)$) desmejoró el rendimiento predictivo, alcanzando el mayor error registrado (MSE = 5,0359). Esto indica que alterar la escala de la variable objetivo distorsionó la relación lineal con los predictores en lugar de optimizarla, confirmando que la escala original de la edad es la más adecuada para preservar la estructura predictiva del modelo lineal.

Se realizó también un gráfico para ver de manera mas sencilla como predice el modelo final:




Figura 5: Predichos vs Real.

La relación entre los valores observados y las predicciones del modelo sobre el conjunto de prueba que se exhibe en la Figura 5 refleja una ligera sobreestimación para edades inferiores a 10, y una subestimación cada vez mayor a medida que los cangrejos aumentaban en edad. Esto se debe a que el modelo no es capaz de capturar la detención de crecimiento de los animales, y por lo tanto un cangrejo de entre 15 y 25 años lo clasifica como uno de entre 13 y 17 aproximadamente.

5. Conclusión Final

El propósito fundamental de este trabajo consistió en desarrollar un modelo de regresión lineal capaz de explicar y predecir con precisión la edad de los cangrejos utilizando variables morfológicas externas de fácil obtención, proveyendo así una alternativa eficiente y de bajo costo operativo para la gestión sostenible en la pesquería y la optimización de cosechas en criaderos. Tras un riguroso proceso de modelación y diagnóstico estadístico, se han alcanzado conclusiones determinantes que responden directamente a dicho objetivo.

En primer lugar, se demostró que es metodológicamente viable sustituir los diagnósticos complejos de laboratorio por mediciones físicas externas. Sin embargo, el estudio de la estructura de los datos reveló que la optimización del modelo exige aceptar un compromiso regulado entre parsimonia y precisión predictiva. El algoritmo Lasso cumplió exitosamente el objetivo de aislar el ruido interpretativo provocado por la colinealidad biológica de los pesos y dimensiones, seleccionando un subconjunto óptimo de cinco predictores estructurales (*Diameter*, *Height*, *Shucked.Weight*, *Shell.Weight* y la variable categórica unificada *Sex.Det*). Si bien esta simplificación paramétrica conllevó un incremento marginal en el error de predicción respecto al modelo saturado ($MSE_{Lasso} = 4,7732$ frente a $MSE_{Sat} = 3,9860$), otorgó a cambio una estructura robusta y teóricamente válida para la inferencia estadística individual.

En segundo lugar, la evaluación del desempeño en el conjunto de prueba independiente (*Test Set*) permitió validar la utilidad práctica del modelo refinado, exponiendo a su vez sus límites biológicos. La herramienta alcanza su máxima eficacia y precisión en la estimación de ejemplares jóvenes y adultos en etapas intermedias (edades entre 3 y 11 años), cubriendo con éxito el rango de mayor relevancia para la regulación de capturas prematuras en la actividad pesquera. No obstante, ante la senectud de los especímenes, el estancamiento natural del crecimiento físico induce una subestimación sistemática en las predicciones, fijando un techo predictivo asintótico en torno a los 14 años.

6. Consideraciones a Futuro

Como se demostró en el apartado de Desempeño Predictivo, el Modelo alcanza un techo provocado por las características biológicas de los cangrejos. Una forma de poder mejorar esto podría ser implementando dos modelos por separado, o incluso más, en los cuales a partir de una o más variables y sus resultados, el algoritmo arroje unos estimadores de $\hat{\beta}$ específicos según en que etapa se cree que puede estar el cangrejo analizado.

Referencias

- [1] Lumley, T., Diehr, P., Emerson, S., & Chen, L. (2002). *The importance of the normality assumption in large public health data sets*. Annual Review of Public Health, 23(1), 151-169.
- [2] Wooldridge, J. M. (2015). *Introductory Econometrics: A Modern Approach*. Cengage Learning (6th Edition).
- [3] Cribari-Neto, F. (2004). Asymptotic inference under heteroskedasticity of unknown form. *Computational Statistics & Data Analysis*, 45(2), 215-233. <https://link.springer.com/article/10.3758/BF03192961>
- [4] Wang, J., Liu, Y., & Zhang, L. (2024). Gender Identification of Chinese Mitten Crab Juveniles Based on Improved Faster R-CNN. *Applied Sciences*, 14(3), 1105. <https://www.mdpi.com/2076-3417/14/3/1105>
- [5] EVA de Modelos Lineales. (2026). *Materiales teóricos y scripts practicos*. Facultad de Ciencias Económicas y de Administración, Universidad de la República.
- [6] Sidhu, S. (2022). *Crab Age Prediction Dataset*. Kaggle. <https://www.kaggle.com/datasets/sidhus/crab-age-prediction>
- [7] Oregon Department of Fish and Wildlife. (2026). How to Crab. <https://myodfw.com/articles/how-crab>
- [8] StoneCrab.com. (2026). Why Some Fresh Stone Crab Claws Have More Sweetness Than Others. <https://stonecrab.com/blogs/news/why-some-fresh-stone-crab-claws-have-more-sweetness-than-others>